

CNN-LSTM 모델 기반 Bearing RUL 예측

팀명: 파머완

1. 문제 정의


본 과제는 베어링의 진동 데이터를 기반으로 잔존수명(RUL, Remaining Useful Life)을 예측하는 모델을 개발하는 것이다. 주어진 TDMS 데이터를 바탕으로 고장 시점을 예측하고, 유지보수 효율성을 높이는 것이 목표다

2. 데이터 전처리 및 특징 추출

총 8개의 학습 세트 중, Train 1, 4, 5, 7, 8은 중단 조건에 도달한 data point가 포함된 고장 데이터, Train 2, 3, 6은 중단 조건 도달 data point가 포함되지 않은 데이터로 분류하였다.

1) RUL 라벨링

- 중단 조건 포함 세트의 경우, 다음 두 조건 중 먼저 도달한 시점을 고장 시점 $T_{failure}$ 로 정의하였다.
 - Torque ≤ -17 Nm
 - TC SP Front 또는 TC SP Rear $\geq 200^{\circ}\text{C}$
- 잔존 수명(RUL)은 $T_{failure}$ 까지 남은 시점을 기준으로 계산하였다. 시간 index를 초 단위(time(s))로 설정하여 추가 스케일링을 진행하지 않았다.
- 중단 조건 미포함 세트의 경우, 데이터를 분석한 결과, torque보다 temperature가 먼저 중단 조건에 근접하는 경향을 보여, 마지막 3~5개의 온도 데이터를 기반으로 선형 회귀를 수행하여 온도가 200°C 에 도달할 것으로 예상되는 시점을 $T_{failure}$ 로 추정하고, 이에 기반한 RUL 라벨을 부여하였다. 또한 회귀 결정계수(R^2)가 0.85 이상일 경우만 유효한 예측으로 간주하도록 하였다.



2) 특징 추출 (Feature Engineering)

- 샘플링 및 윈도우 설정
 - 진동 데이터는 25.6kHz로 수집되었으며, 총 256000개 샘플 중 일정 구간만 사용하였다.
 - window size = 25,600 (1초 단위)
 - overlap = 50%
 - 전체 분석 샘플 수 고정: 256,000
- vibration data 특징 (CH1~CH4)
 - Wavelet Packet Transform (WPT): db4 파형 기준, level 3까지 분해하였다.
 - 각 노드에 대해 FFT 적용 후, bandwidth=5 기준으로 주파수 대역을 나누어 에너지 계산하였다.
 - 고장과 연관된 주요 주파수 대역 중심 (BPFI=140Hz, BPFO=93Hz, BSF=78Hz, Cage=6.7Hz)
 - 전체 노드 중 에너지 기준 상위 Top 10 노드 선택
- operation data 특징 (torque, temperature)
 - Torque Slope / Temperature Slope: 최근 N개 시점의 변화를 계산
 - 복합 지표: Temp Slope \times Torque Slope
 - 해당 특징은 베어링 열화의 기계적/열적 변화를 동시에 반영하도록 설계하였다.

3. 모델 구조

Conv1D + LSTM 기반 RUL 예측 모델

- 입력: 윈도우 단위 시계열 특징 벡터
- Conv1D Layer
 - 필터: 8, 커널 크기: 3, Padding: 'causal', Activation: ReLU
 - 목적: 주파수 특징의 지역적 패턴 포착
- MaxPooling + Dropout(0.2)
- LSTM Layer
 - 유닛: 16, Return Sequence: False, L2 정규화 적용
 - 목적: 시계열 내 의존성 학습
- Dropout(0.3)
- Dense Layer: 출력 1 (선형 회귀 -> RUL 예측)

4. 학습 방식

- 손실함수: MSE
- 최적화: Adam (learning rate = 0.0001)
- 배치 크기: 32, 최대 epoch: 100
- 학습 안정성
 - EarlyStopping : patience=7
 - ReduceLROnPlateau: factor=0.5, min_lr=1e-5
 - Dropout(0.2, 0.3)


5. 평가 및 결과

- 사용 모델: 1D CNN-LSTM 회귀 모델
- 총 파라미터 수: 1,649개
- 손실 감소 양상: 초기 val_loss: 0.179 -> 최종 val_loss: 0.0114

Validation1	14010.48926
Validation2	52637.69531
Validation3	36071.5625
Validation4	62839.85938
Validation5	59042.22266
Validation6	32259.23438

MCNN vs CNN 성능비교

MCNN 구조는 더 많은 파라미터와 높은 표현력을 가지지만, 데이터의 제한으로 인해 과적합 현상이 발생하였다. 반면, 단일 CNN 구조는 MCNN에 비해 일반화 성능이 높아 1D CNN을 선택하게 되었다.



6. 결론 및 향후 개선 방향

CNN-LSTM 모델로 주파수 데이터의 특징을 파악하고 시계열 형태를 살려 학습에 활용할 수 있음을 알 수 있다.

또한 Wavelet Packet Transform(WPT)과 FFT를 이용하여 주요 주파수 특징을 추출하였으나, 향후에는 물리 기반 특성과 통계적 신호 특성의 융합을 통해 모델의 예측 성능 향상을 기대할 수 있다.

